

## Documentacao do Projeto A3

Comite de Classificadores aplicado a deteccao de asteroides potencialmente perigosos

**Disciplina:** Inteligencia Artificial

**Instituicao:** Universidade Sao Judas Tadeu

**Base de dados:** NASA JPL Small-Body Database (sbdb\_asteroides.csv)

**Variavel alvo:** pha (Potentially Hazardous Asteroid)

**Data:** 25 / 05 / 2026

# 1. Visao geral do projeto

O projeto atende a avaliacao A3 da disciplina de Inteligencia Artificial e consiste na construcao de um **comite de classificadores (ensemble)** para resolver um problema de classificacao supervisionada. Foi escolhida a base publica **NASA JPL Small-Body Database**, que reúne parametros orbitais e fisicos de pequenos corpos do sistema solar.

O objetivo de inferencia e **prever se um asteroide e potencialmente perigoso para a Terra** (rotulo PHA - Potentially Hazardous Asteroid). Trata-se de um problema de classificacao binaria com classes fortemente desbalanceadas: a classe positiva representa apenas cerca de 0,18% do dataset original.

## 1.1 Variavel alvo

- **pha**: assume os valores 'Y' (perigoso) ou 'N' (nao perigoso).
- Foi codificada como **1** para 'Y' e **0** para 'N'.

## 1.2 Features selecionadas

Foram utilizadas oito features, todas parametros orbitais ou fisicos do asteroide, exatamente como disponibilizadas pela base SBDB:

- **q, ad, H, ma, per, e, a, i** (detalhadas no proximo capitulo).

**Decisao deliberada:** os campos `moid` (menor distancia entre as orbitas) e `neo` (Near Earth Object) **NAO** foram usados como features, mesmo estando disponiveis na base. A definicao oficial de PHA depende diretamente de ambos, e inclui-os configuraria **vazamento de dados (data leakage)**: o modelo aprenderia a propria definicao do rotulo em vez de inferir o padrao a partir de parametros orbitais.

# 2. Glossario dos parametros orbitais

As oito features do modelo correspondem aos parametros keplerianos classicos da orbita do asteroide ao redor do Sol mais a magnitude absoluta. A tabela abaixo descreve cada um.

| Sigla | Nome                  | Unidade | Descricao                                                                                                                       |
|-------|-----------------------|---------|---------------------------------------------------------------------------------------------------------------------------------|
| q     | Distancia do perielio | AU      | Menor distancia da orbita ao Sol. Critica para PHA: quanto menor q, mais perto da Terra o asteroide pode chegar.                |
| ad    | Distancia do afelio   | AU      | Maior distancia da orbita ao Sol. Junto com q, delimita a extensao radial da orbita.                                            |
| H     | Magnitude absoluta    | (adim.) | Brilho intrinseco; serve como proxy de tamanho. $H \leq 22$ e um dos criterios oficiais de PHA (~140 m). Menor H = corpo maior. |
| ma    | Anomalia media        | graus   | Posicao angular do asteroide na orbita em um instante de referencia. Indica onde o corpo esta na trajetoria.                    |

| Sigla | Nome               | Unidade | Descricao                                                                                                                                               |
|-------|--------------------|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| per   | Periodo orbital    | dias    | Tempo de uma volta completa em torno do Sol. Relaciona-se com 'a' pela terceira lei de Kepler ( $a^3$ proporcional a $per^2$ ).                         |
| e     | Excentricidade     | 0 a 1   | Quao alongada e a orbita. $e=0$ e circulo perfeito; e proximo de 1 e orbita muito alongada. e alto + a proximo da Terra favorece cruzamento de orbitas. |
| a     | Semi-eixo maior    | AU      | Raio medio da orbita. Determina o tamanho geral. Vale $a = (q + ad)/2$ .                                                                                |
| i     | Inclinacao orbital | graus   | Angulo entre o plano orbital do asteroide e o plano da ecliptica (plano da orbita da Terra). i baixo significa orbita no mesmo plano da Terra.          |

### Por que esse conjunto faz sentido para prever PHA

A definicao oficial de PHA combina dois criterios: (1) o asteroide chegar suficientemente perto da Terra, e (2) ser grande o bastante para causar dano significativo. O conjunto escolhido cobre os dois sem usar os campos derivados:

- Proximidade da Terra: capturada por **q, a, e, i** (geometria da orbita).
- Tamanho do corpo: capturado por **H** (proxy fotometrico).
- Dinamica temporal: **per** e **ma** complementam descrevendo o movimento e fase orbital.

### 3. Pipeline de processamento

O pipeline implementado no arquivo `projeto_a3_comite_classificadores.py` segue rigorosamente as etapas 3.3 a 3.6 do enunciado A3.

#### 3.1 Carregamento e EDA basica

- Leitura do CSV bruto (~162 MB) em `projeto_a3/data/raw/sbdb_asteroides.csv`.
- Verificacao da distribuicao do rotulo: classe positiva representa apenas ~0,18% do total.

#### 3.2 Pre-processamento

- Remocao de linhas sem rotulo (target nao pode ser NaN).
- Codificacao do target: Y -> 1, N -> 0.
- Selecao das 8 features ja descritas, sem moid/neo.
- Imputacao de valores ausentes pela **mediana** (robusta a outliers, comuns em parametros orbitais).

#### 3.3 Balanceamento (undersampling 1:3)

Sem balanceamento, qualquer modelo aprende a 'chutar tudo N' e atinge 99,8% de acuracia inutil. A estrategia adotada foi:

- Manter **todos** os exemplos positivos (PHA = Y).
- Amostrar aleatoriamente **3x** esse numero de negativos.
- Proporcao final 1:3 (perigoso : nao perigoso) - suficiente para preservar o sinal sem perder muita informacao.

#### 3.4 Split treino/teste e padronizacao

- Divisao 75% treino / 25% teste, **estratificada** pelo target.
- `StandardScaler` ajustado no treino e aplicado no teste.
- KNN, SVM e MLP exigem features na mesma escala; Decision Tree e Naive Bayes nao precisam, mas usar o scaler para todos simplifica o pipeline sem prejuizo.

#### 3.5 Modelos individuais (cinco, acima do minimo de tres)

| Modelo        | Hiperparametros principais   | Justificativa                                                                                  |
|---------------|------------------------------|------------------------------------------------------------------------------------------------|
| KNN           | <code>n_neighbors = 5</code> | Baseline simples baseado em distancia; sensivel a escala (por isso o scaler).                  |
| Naive Bayes   | GaussianNB padrao            | Modelo probabilistico rapido; assume independencia condicional - util como referencia.         |
| Decision Tree | <code>max_depth = 8</code>   | Captura interacoes nao-lineares; interpretavel; profundidade limitada para evitar overfitting. |

| Modelo | Hiperparametros principais       | Justificativa                                                    |
|--------|----------------------------------|------------------------------------------------------------------|
| SVM    | kernel = RBF, probability = True | Fronteira nao-linear; probability=True habilita soft voting.     |
| MLP    | camadas (64, 32), max_iter = 400 | Rede neural rasa; aprende combinacoes nao-lineares das features. |

### 3.6 Construcao do comite (VotingClassifier)

Foram implementadas duas variantes de comite usando `sklearn.ensemble.VotingClassifier`:

- **Soft voting (escolhido como principal):** votacao ponderada pelas probabilidades preditas. Um classificador inseguro (prob ~0,51) pesa menos no resultado final do que um confiante (prob ~0,99). Gera resultados mais estaveis quando os modelos tem desempenho heterogeneo (caso aqui: Naive Bayes versus MLP).
- **Hard voting (comparativo):** apenas voto majoritario dos rotulos preditos, sem considerar confianca.

### 3.7 Avaliacao

- Metricas exigidas pelo enunciado: **Accuracy, Precision, Recall, F1-score** e **matriz de confusao**.
- **Validacao cruzada estratificada de 5 folds** aplicada ao comite soft, calculando F1 por fold e a media.
- Exportacao automatica de `comparacao_metricas.png` e `matrizes_confusao.png`.

## 4. Resultados obtidos

Os valores abaixo foram extraídos de `projeto_a3/outputs/metrics/relatorio_metricas.csv`.

| Modelo                  | Accuracy | Precision | Recall | F1-Score |
|-------------------------|----------|-----------|--------|----------|
| KNN                     | 0,9893   | 0,9589    | 1,0000 | 0,9790   |
| Naive Bayes             | 0,9687   | 0,8986    | 0,9863 | 0,9404   |
| Decision Tree           | 0,9949   | 0,9847    | 0,9949 | 0,9898   |
| SVM                     | 0,9914   | 0,9669    | 1,0000 | 0,9832   |
| MLP                     | 0,9949   | 0,9799    | 1,0000 | 0,9898   |
| Random Forest           | 0,9957   | 0,9832    | 1,0000 | 0,9915   |
| Comite Soft Voting      | 0,9944   | 0,9782    | 1,0000 | 0,9890   |
| Comite Hard Voting      | 0,9949   | 0,9799    | 1,0000 | 0,9898   |
| Comite Soft + Threshold | 0,9919   | 0,9685    | 1,0000 | 0,9840   |

### Leitura dos resultados

- **Melhor individual:** Random Forest (F1 = 0,9915), com Recall = 1,0000.
- **Comite Soft Voting:** F1 = 0,9890 - praticamente empatado com os melhores individuais, mantendo Recall = 1,0000.
- **Recall maximo** em quase todos os modelos significa que nenhum asteroide perigoso foi classificado como nao perigoso no conjunto de teste - propriedade desejavel para o problema, ja que o custo de um falso negativo (deixar passar um asteroide perigoso) e muito maior que o de um falso positivo.
- Naive Bayes foi o pior individual (F1 = 0,9404), provavelmente por violar a hipotese de independencia entre features orbitais que sao fortemente correlacionadas (por exemplo,  $a$ ,  $q$ ,  $ad$ ).

### O comite melhorou?

Numericamente, o comite nao superou o melhor individual (Random Forest). Porem, ele agregou robustez: combinou cinco modelos com vieses diferentes e manteve metricas no patamar dos melhores, com Recall = 1,0. Em producao, isso reduz a chance de uma falha sistematica de um unico classificador comprometer a decisao.

## 5. Top 5 asteroides com maior risco de colisao

A partir dos 2.335 asteroides classificados como PHA (pha = Y) na base SBDB, foram selecionados os cinco com maior **risco geometrico de colisao**, definido pelo menor valor de **MOID** (Minimum Orbit Intersection Distance) - a menor distancia possivel entre a orbita do asteroide e a orbita da Terra. Quanto menor o MOID, mais proximas as duas orbitas chegam de se interceptar.

Os cinco asteroides aparecem na ordem da tabela abaixo (sem ranking de ameaca, conforme solicitado). Os dados foram extraidos do log projeto\_a3/outputs/logs/top5\_asteroides\_risco.csv.

| Designacao | Diametro est. | MOID        | MOID (km) | Periodo orbital | Classe |
|------------|---------------|-------------|-----------|-----------------|--------|
| 2016 FG60  | ~159 m        | 0,000021 AU | 3.097 km  | 1,67 anos       | APO    |
| 2018 LK    | ~136 m        | 0,000031 AU | 4.593 km  | 1,10 anos       | APO    |
| 2014 PW59  | ~412 m        | 0,000031 AU | 4.667 km  | 3,78 anos       | APO    |
| 2012 TY52  | ~168 m        | 0,000099 AU | 14.855 km | 2,15 anos       | APO    |
| 2021 NQ5   | ~172 m        | 0,000104 AU | 15.558 km | 2,05 anos       | APO    |

### Sobre os valores de tamanho

Nenhum dos cinco asteroides tem o campo diameter preenchido na base. O diametro foi **estimado a partir da magnitude absoluta H** e do albedo, usando a formula astronomica padrao:

$$D \text{ (km)} = 1329 / \sqrt{\text{albedo}} * 10^{(-0,2 * H)}$$

Como tambem nao havia albedo medido, foi adotado o valor **0,19** (media dos PHAs com dado de albedo conhecido). Os diametros listados sao portanto aproximacoes - todos estao entre **136 e 412 metros**, com quatro deles na faixa de **~140-170 metros**, exatamente o tamanho que dispara o criterio oficial de PHA ( $H \leq 22$ ).

### Sobre o tempo para que uma colisao aconteca

A base SBDB nao contem previsao de impacto. O campo MOID indica apenas a **distancia minima geometrica** entre as duas orbitas - nao que o asteroide va estar nesse ponto no mesmo instante que a Terra. Previsoes reais de impacto exigem integracao numerica das equacoes de movimento (sistema Sentry do JPL).

O que podemos extrair da base como proxy temporal e o **periodo orbital**, que define a **cadencia das aproximacoes**: a cada periodo, o asteroide retorna a configuracao orbital que o coloca novamente perto do MOID. Para os cinco asteroides:

- **2018 LK** (periodo 1,10 anos): janela de aproximacao mais frequente, aproximadamente uma vez por ano.
- **2016 FG60** (1,67 anos): retorna a cada ~20 meses; combina ciclo curto com o menor MOID do grupo (3.097 km).
- **2021 NQ5** (2,05 anos) e **2012 TY52** (2,15 anos): aproximacoes a cada ~2 anos.

- **2014 PW59** (3,78 anos): cadencia mais espacada, porem e o maior do grupo (diametro estimado de ~412 m).

Em termos comparativos:

- O MOID de 3.097 km do **2016 FG60** equivale a **0,8%** da distancia Terra-Lua (384.400 km) - o ponto mais proximo das duas orbitas esta praticamente dentro da magnetosfera terrestre.
- Os cinco pertencem a classe orbital **APO (Apollo)**: tem semi-eixo maior  $> 1$  AU e perielio  $< 1,017$  AU - ou seja, suas orbitas cruzam a da Terra por dentro, caracteristica que os torna candidatos naturais a PHA.

### Limitacoes desta analise

- MOID e uma metrica **estatica**: o valor pode evoluir ao longo do tempo por efeito de perturbacoes gravitacionais (Jupiter, demais planetas) e do efeito Yarkovsky.
- Risco **real** de impacto e estimado pela NASA via simulacao n-corpos (API Sentry); este projeto apresenta apenas o ranking geometrico extraido da SBDB.
- Para um estudo mais completo, integrar a Sentry API ([ssd-api.jpl.nasa.gov/sentry.api](https://ssd-api.jpl.nasa.gov/sentry.api)) permitiria reportar probabilidade de impacto e janela temporal explicita - linha de trabalho futura.



## 6. Estrutura de arquivos do repositório

```
AI/
|-- Projeto A3 20261 Enunciado.pdf      (enunciado oficial)
|-- projeto_a3_comite_classificadores.py (script principal autocontido)
|-- analisis-de-asteroides.ipynb       (notebook de EDA de referencia)
|-- comparacao_metricas.png             (saida do script)
|-- matrizes_confusao.png               (saida do script)
|-- projeto_a3/                         (versao organizada)
|   |-- data/
|       |-- raw/sbdb_asteroides.csv      (~162 MB)
|       |-- processed/
|   |-- src/                            (modulos do projeto)
|   |-- outputs/
|       |-- figures/ (8 graficos: target, heatmap, PCA, CM, ROC, PR, FI)
|       |-- metrics/relatorio_metricas.csv
|       |-- logs/top5_asteroides_risco.csv
|       |-- models/
|-- reports/Documentacao_Projeto_A3.pdf
```

### Observacao sobre projeto\_a3/src/

O diretorio projeto\_a3/src/ contem apenas `__pycache__` com os bytecodes compilados (carregamento, preprocessamento, balanceamento, modelos, ensemble, avaliacao, visualizacoes, config). Os arquivos-fonte .py correspondentes nao estao presentes - recomenda-se restaura-los antes da entrega final, pois o enunciado pede codigo organizado e comentado.

## 7. Cobertura dos requisitos do enunciado

| Item do enunciado                                   | Status       | Onde no projeto                                                                           |
|-----------------------------------------------------|--------------|-------------------------------------------------------------------------------------------|
| 3.1 Base de dados publica + justificativa           | Atendido     | NASA JPL SBDB (Kaggle/oficial); problema de classificacao binaria.                        |
| 3.2 Target e features bem definidos                 | Atendido     | Target = pha; 8 features orbitais; data leakage evitado.                                  |
| 3.3 Pre-processamento (NaN, encoding, scaling, EDA) | Atendido     | Imputacao por mediana; codificacao binaria; StandardScaler; EDA no notebook.              |
| 3.4 Pelo menos 3 classificadores                    | Atendido (5) | KNN, Naive Bayes, Decision Tree, SVM, MLP.                                                |
| 3.5 Comite com estrategia justificada               | Atendido     | Soft voting (principal) e hard voting (comparativo).                                      |
| 3.6 Metricas e matriz de confusao                   | Atendido     | Accuracy, Precision, Recall, F1, CM, classification_report, 5-fold CV.                    |
| 3.7 Analise e conclusoes                            | Parcial      | Resultados quantitativos prontos; discussao textual a ser consolidada no relatorio final. |

## 8. Limitacoes e proximos passos sugeridos

- **Undersampling agressivo:** ao manter apenas 3x os positivos, descartamos a maior parte dos negativos. Vale comparar com SMOTE ou `class_weight='balanced'` para preservar mais informacao.
- **Dependencia da semente aleatoria:** o balanceamento e o split dependem de `random_state=42`; rodar varias seeds e reportar media e desvio daria mais robustez.
- **Tuning de hiperparametros:** os modelos foram usados com hiperparametros razoaveis porem nao otimizados; GridSearchCV ou Optuna poderiam melhorar marginalmente.
- **Integrar a API Sentry da NASA** para reportar probabilidade de impacto e janela temporal explicita dos PHAs do top 5.
- **Restaurar os modulos em src/:** hoje so existem os `.pyc`; recomenda-se ter o codigo-fonte versionado.
- **Consolidar o relatorio PDF do enunciado:** este documento descreve o projeto, mas o entregavel formal pedido na secao 4.2 do enunciado (Introducao, Descricao da base, Definicao do problema, Pre-processamento, Modelagem, Comite, Resultados, Discussao, Conclusao) ainda precisa ser produzido como entregavel final.