

UNIVERSIDADE SÃO JUDAS TADEU
DISCIPLINA: INTELIGÊNCIA ARTIFICIAL

PROJETO A3 — COMITÊ DE CLASSIFICADORES

**Predição de Asteroides Potencialmente Perigosos para a
Terra Utilizando Machine Learning**

2026

1. Integrantes

Nome	RA
Matheus Santos Morais Arruda	825218417
Lucca Campello Rodrigues dos Santos	82525684
Jorge Antonio de Paula Tosi	825220685
Guilherme Caposse Tabler	825126059
Matheus Miano	82425432

2. Introdução

Este trabalho foi desenvolvido para a disciplina de Inteligência Artificial da Universidade São Judas Tadeu como parte da avaliação A3. O projeto consiste na construção de um sistema de classificação supervisionada utilizando um comitê de classificadores (ensemble) aplicado à detecção de asteroides potencialmente perigosos para a Terra.

O principal objetivo do projeto é aplicar conceitos de aprendizado de máquina supervisionado, incluindo pré-processamento de dados, balanceamento de classes, treinamento de múltiplos modelos, validação cruzada, métricas de avaliação e construção de ensembles.

Foi utilizado um dataset público da NASA JPL Small-Body Database, disponibilizado no Kaggle em formato CSV, contendo parâmetros orbitais e físicos de pequenos corpos do sistema solar.

3. Descrição da Base de Dados

A base de dados utilizada foi extraída da NASA Jet Propulsion Laboratory Small-Body Database (SBDB), contendo informações orbitais e físicas de asteroides próximos à Terra.

A escolha da base foi motivada pela relevância científica do problema e pela adequação ao contexto de classificação supervisionada. O dataset apresenta dados reais utilizados em estudos astronômicos e possibilita a aplicação prática de técnicas modernas de Machine Learning.


A variável alvo(target) do projeto foi:

- PHA (Potentially Hazardous Asteroid)

Classes:

- 1 → Asteroide potencialmente perigoso
- 0 → Asteroide não perigoso


Balanceamento de Classes



4. Features Utilizadas (Variáveis Independentes)

As principais features utilizadas foram:

- q — distância do periélio
- ad — distância do afélio
- H — magnitude absoluta
- ma — anomalia média
- per — período orbital
- e — excentricidade orbital
- a — semi-eixo maior
- i — inclinação orbital



As variáveis MOID e NEO foram removidas propositalmente para evitar data leakage, uma vez que estão diretamente relacionadas à definição oficial de um asteroide potencialmente perigoso.

5. Pré-processamento dos Dados

O pipeline de pré-processamento foi desenvolvido para garantir maior qualidade e estabilidade durante o treinamento dos modelos.

As principais etapas foram:


- Remoção de registros sem target definido
- Conversão da variável alvo em representação binária
- Tratamento de valores ausentes utilizando imputação por mediana
- Padronização dos dados utilizando StandardScaler
- Balanceamento de classes utilizando undersampling

O dataset original apresentava forte desbalanceamento, com apenas aproximadamente 0,18% dos registros pertencendo à classe positiva. Sem balanceamento, os modelos tenderiam a prever apenas a classe majoritária.

6. Modelagem

Foram implementados cinco modelos supervisionados distintos:

- K-Nearest Neighbors (KNN)
- Gaussian Naive Bayes
- Decision Tree
- Support Vector Machine (SVM)
- Multi-Layer Perceptron (MLP)



Cada modelo foi treinado individualmente e posteriormente comparado utilizando métricas estatísticas.

Também foi implementado um modelo Random Forest para comparação adicional e análise de importância das features.

7. Comitê de Classificadores

Após o treinamento dos modelos individuais, foi construído um comitê de classificadores utilizando VotingClassifier da biblioteca Scikit-Learn.

Foram comparadas duas estratégias:

- Hard Voting
- Soft Voting

O método Soft Voting apresentou maior estabilidade, pois considera as probabilidades

previstas por cada classificador, reduzindo o impacto de modelos menos confiáveis.

8. Avaliação dos Modelos

Os modelos foram avaliados utilizando as métricas exigidas no enunciado da atividade:

- Accuracy
- Precision
- Recall
- F1-Score
- Matriz de Confusão


Também foram utilizadas:

- Curvas ROC
- Curvas Precision-Recall
- Validação cruzada estratificada (5-fold)

O recall recebeu atenção especial devido ao contexto do problema. Em cenários de detecção de risco orbital, falsos negativos representam asteroides perigosos classificados como seguros.

9. Resultados Obtidos

Modelo	Accuracy	Precision	Recall	F1-Score
KNN	0.9893	0.9589	1.0000	0.9790
Naive Bayes	0.9687	0.8986	0.9863	0.9404
Decision Tree	0.9949	0.9847	0.9949	0.9898
SVM	0.9914	0.9669	1.0000	0.9832
MLP	0.9949	0.9799	1.0000	0.9898
Random Forest	0.9957	0.9832	1.0000	0.9915
Comitê Soft Voting	0.9944	0.9782	1.0000	0.9890



10. Discussão dos Resultados

Os resultados demonstraram excelente desempenho dos modelos supervisionados utilizados no projeto.

O Random Forest apresentou o melhor desempenho individual, atingindo F1-Score de 0.9915 e Recall igual a 1.0, indicando que nenhum asteroide perigoso foi classificado incorretamente como seguro no conjunto de teste.

O comitê Soft Voting manteve desempenho extremamente próximo dos melhores modelos individuais, demonstrando robustez e estabilidade nas previsões.

As curvas ROC e Precision-Recall indicaram alta capacidade discriminativa dos modelos, especialmente considerando o forte desbalanceamento do dataset.

11. Top 5 Asteroides com Maior Risco Geométrico

Com base no valor de MOID (Minimum Orbit Intersection Distance), foram identificados os cinco asteroides potencialmente mais próximos da órbita terrestre.

Esses asteroides pertencem à classe orbital APO (Apollo), caracterizada por órbitas que cruzam a órbita da Terra.

A análise demonstrou que o pipeline desenvolvido foi capaz de identificar corretamente

asteroides classificados oficialmente como PHA, validando o funcionamento do sistema proposto.

Designação	Diâmetro	MOID	Período Orbital	Classe
2016 FG60	~159m	0,000021 AU	1,67 anos	APO
2018 LK	~136m	0,000031 AU	1,10 anos	APO
2014 PW59	~412m	0,000031 AU	3,78 anos	APO
2012 TY52	~168m	0,000099 AU	2,15 anos	APO
2021 NQ5	~172m	0,000104 AU	2,05 anos	APO

MOID (Minimum Orbit Intersection Distance ou Distância Mínima de Interseção Orbital) mede a distância mais curta possível entre a órbita de um corpo (como um asteroide) e a da Terra. Quanto menor for o valor do MOID, mais perto as órbitas se cruzam e, portanto, maior é o risco de colisão

12. Conclusão

O projeto atingiu os objetivos propostos pela disciplina de Inteligência Artificial, aplicando técnicas de aprendizado supervisionado e construção de ensembles em um problema real de classificação.

Os modelos desenvolvidos apresentaram desempenho elevado, especialmente nos critérios de Recall e F1-Score, fundamentais para cenários de detecção de risco orbital.

A análise dos cinco asteroides com menor MOID demonstrou que o sistema foi capaz de identificar corretamente objetos potencialmente perigosos, validando a eficiência do pipeline de Machine Learning implementado.

13. Referências

NASA Jet Propulsion Laboratory Small-Body Database.

Scikit-learn Documentation.

Kaggle — NASA Asteroid Dataset.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning.